

$$w(t+1) = w(t) - \rho \frac{\partial \mathcal{L}(w)}{\partial w} w(t)$$

$\mathcal{L}(w)$: Loss function
 ρ : Learning rate
 $\frac{\partial \mathcal{L}(w)}{\partial w}$: Gradient of loss with respect to weights

در این مثال می‌خواهیم یک خطای کمترین مربعات را پیدا کنیم

خطای مربعات (کوچک)

correction vector

$$w(t+1) = w(t) - \rho \sum_{n \in Y} \delta_n x_n$$

این را می‌توانیم به کار بستیم
 و می‌توانیم به کار بستیم

در اینجا ما داریم به دنبال این هستیم که خطای کمترین مربعات را پیدا کنیم

ما این را می‌توانیم به کار بستیم

در اینجا ما داریم به دنبال این هستیم که خطای کمترین مربعات را پیدا کنیم

ما این را می‌توانیم به کار بستیم

در اینجا ما داریم به دنبال این هستیم که خطای کمترین مربعات را پیدا کنیم

ما این را می‌توانیم به کار بستیم

جملہ نالی دھو کر

thermat loss

ازدیت

بہت زیادہ

مہانہ

اگر کوئی

نہ ہو

تو

کے

توضیح: این فرمولها را در نظر بگیرید

حالا ما می‌خواهیم این فرمولها را بنویسیم:

$$w(t+1) = w(t) - \eta \sum_{n \in \mathcal{P}} \delta_n w(t)$$

$$w(t+1) = w(t) - \eta \sum_{n \in \mathcal{P}} \delta_n w(t)$$

$$w(t+1) = w(t) - \eta \sum_{n \in \mathcal{P}} \delta_n w(t)$$

$$w(t+1) = w(t) - \eta \sum_{n \in \mathcal{P}} \delta_n w(t)$$

$$w(t+1) = w(t) - \eta \sum_{n \in \mathcal{P}} \delta_n w(t)$$

$$w(t+1) = w(t) - \eta \sum_{n \in \mathcal{P}} \delta_n w(t)$$

$$w(t+1) = w(t) - \eta \sum_{n \in \mathcal{P}} \delta_n w(t)$$

$$w(t+1) = w(t) - \eta \sum_{n \in \mathcal{P}} \delta_n w(t)$$

$$w(t+1) = w(t) - \eta \sum_{n \in \mathcal{P}} \delta_n w(t)$$

$$w(t+1) = w(t) - \eta \sum_{n \in \mathcal{P}} \delta_n w(t)$$

$$w(t+1) = w(t) - \eta \sum_{n \in \mathcal{P}} \delta_n w(t)$$

$$w(t+1) = w(t) - \eta \sum_{n \in \mathcal{P}} \delta_n w(t)$$

$$w(t+1) = w(t) - \eta \sum_{n \in \mathcal{P}} \delta_n w(t)$$

$$w(t+1) = w(t) - \eta \sum_{n \in \mathcal{P}} \delta_n w(t)$$

$$w(t+1) = w(t) - \eta \sum_{n \in \mathcal{P}} \delta_n w(t)$$

$$w(t+1) = w(t) - \eta \sum_{n \in \mathcal{P}} \delta_n w(t)$$

$$w(t+1) = w(t) - \eta \sum_{n \in \mathcal{P}} \delta_n w(t)$$

$$w(t+1) = w(t) - \eta \sum_{n \in \mathcal{P}} \delta_n w(t)$$

$$w(t+1) = w(t) - \eta \sum_{n \in \mathcal{P}} \delta_n w(t)$$

$$w(t+1) = w(t) - \eta \sum_{n \in \mathcal{P}} \delta_n w(t)$$

$$w(t+1) = w(t) - \eta \sum_{n \in \mathcal{P}} \delta_n w(t)$$

$$w(t+1) = w(t) - \eta \sum_{n \in \mathcal{P}} \delta_n w(t)$$

$$w(t+1) = w(t) - \eta \sum_{n \in \mathcal{P}} \delta_n w(t)$$

$$w(t+1) = w(t) - \eta \sum_{n \in \mathcal{P}} \delta_n w(t)$$

$$w(t+1) = w(t) - \eta \sum_{n \in \mathcal{P}} \delta_n w(t)$$

$$w(t+1) = w(t) - \eta \sum_{n \in \mathcal{P}} \delta_n w(t)$$

$$w(t+1) = w(t) - \eta \sum_{n \in \mathcal{P}} \delta_n w(t)$$

$$w(t+1) = w(t) - \eta \sum_{n \in \mathcal{P}} \delta_n w(t)$$

$$w(t+1) = w(t) - \eta \sum_{n \in \mathcal{P}} \delta_n w(t)$$

$$w(t+1) = w(t) - \eta \sum_{n \in \mathcal{P}} \delta_n w(t)$$

این فرمولها را در نظر بگیرید

$$0 \leq \|w(t+1) - w^*\| \leq 0 \rightarrow D(w(t+1) - w^*)$$


$$0 \leq \|w(t+1) - w^*\| \leq 0 \rightarrow D(w(t+1) - w^*)$$

$$0 \leq \|w(t+1) - w^*\| \leq 0 \rightarrow D(w(t+1) - w^*)$$

$$0 \leq \|w(t+1) - w^*\| \leq 0 \rightarrow D(w(t+1) - w^*)$$

$$0 \leq \|w(t+1) - w^*\| \leq 0 \rightarrow D(w(t+1) - w^*)$$

$$0 \leq \|w(t+1) - w^*\| \leq 0 \rightarrow D(w(t+1) - w^*)$$



L^2 : MSE (Mean Squared Error)

$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$

L^1 : MAE (Mean Absolute Error)

$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$

MAE is less sensitive to outliers than MSE.



$$MAE = \frac{\sum |y_i - \hat{y}_i|}{n}$$

MAE is less sensitive to outliers than MSE.

MAE is more robust to outliers than MSE.

MAE is more robust to outliers than MSE.

MAE is more robust to outliers than MSE.

MAE is more robust to outliers than MSE.


MAE is more robust to outliers than MSE.

$$MAE < RMSE$$

Smooth Mean Absolute Error (SMAE) and its properties


✓ SMAE is a smooth function

$$L_{SMAE}(y, \hat{y}) = \frac{1}{n} \sum_{i=1}^n \sqrt{\frac{1}{2} (|y_i - \hat{y}_i| + 1)}$$



Optimization of Hyperbolic cosine

$$L_{\log-cosh}(y, \hat{y}) = \frac{1}{n} \sum_{i=1}^n \log(\cosh(y_i - \hat{y}_i))$$



Mean Squared Error (MSE) and its properties

✓ MSE is a smooth function

$$L_{MSE}(y, \hat{y}) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$



Date: / /

موضوع: دیتا سائنس

Subject:

What is a regression model?

A regression model is a statistical model that estimates the relationship between a dependent variable and one or more independent variables.

It is used to predict the value of the dependent variable based on the values of the independent variables.

There are many types of regression models, including linear regression, logistic regression, and polynomial regression.

The most common type of regression model is linear regression.

Linear regression assumes that the relationship between the variables is linear.

It is used to predict the value of the dependent variable based on the values of the independent variables.

Linear regression is a simple and easy-to-use model that can be applied to a wide range of data.

It is a good starting point for understanding regression analysis.

Linear regression is a good choice for many applications, including predicting sales, estimating the effect of advertising, and understanding the relationship between variables.

Linear regression is a good choice for many applications, including predicting sales, estimating the effect of advertising, and understanding the relationship between variables.

Linear regression is a good choice for many applications, including predicting sales, estimating the effect of advertising, and understanding the relationship between variables.

Linear regression is a good choice for many applications, including predicting sales, estimating the effect of advertising, and understanding the relationship between variables.

Linear regression is a good choice for many applications, including predicting sales, estimating the effect of advertising, and understanding the relationship between variables.

Linear regression is a good choice for many applications, including predicting sales, estimating the effect of advertising, and understanding the relationship between variables.

Linear regression is a good choice for many applications, including predicting sales, estimating the effect of advertising, and understanding the relationship between variables.

Linear regression is a good choice for many applications, including predicting sales, estimating the effect of advertising, and understanding the relationship between variables.

Linear regression is a good choice for many applications, including predicting sales, estimating the effect of advertising, and understanding the relationship between variables.

Linear regression is a good choice for many applications, including predicting sales, estimating the effect of advertising, and understanding the relationship between variables.

Linear regression is a good choice for many applications, including predicting sales, estimating the effect of advertising, and understanding the relationship between variables.

Linear regression is a good choice for many applications, including predicting sales, estimating the effect of advertising, and understanding the relationship between variables.

Linear regression is a good choice for many applications, including predicting sales, estimating the effect of advertising, and understanding the relationship between variables.

Linear regression is a good choice for many applications, including predicting sales, estimating the effect of advertising, and understanding the relationship between variables.

Linear regression is a good choice for many applications, including predicting sales, estimating the effect of advertising, and understanding the relationship between variables.

Linear regression is a good choice for many applications, including predicting sales, estimating the effect of advertising, and understanding the relationship between variables.

Linear regression is a good choice for many applications, including predicting sales, estimating the effect of advertising, and understanding the relationship between variables.



Linear Regression

Classmate Pg. 6



$$- [y \log(z) + (1-y) \log(1-z)] \rightarrow \text{cross entropy}$$



max (0.5, 1-0.5) hinge value



$$\log(1 + e^{-y})$$



میر مرتضیٰ علی و میر مرتضیٰ علی

تعداد N گنجه

تعداد آنها یا تابع تقسیم $(D \text{ و } n)$ و

مربع خواهد داد پس پارامتر

$N = \frac{D}{n}$ فقط

N عدد صحیح است (عدد صحیح)

در فرض کلی

مقدار $N(K, H)$ طوری است که H دارای $N(K, H)$ نقطه است
 و $N(K, H)$ نقطه است که H دارای $N(K, H)$ نقطه است

$$\varepsilon(h) \leq \left(\min_{h \in H} \varepsilon(h) \right) + O \left(\sqrt{\frac{1}{n} \log \frac{1}{\varepsilon}} \right) + \frac{1}{n} \log \left(\frac{1}{\varepsilon} \right)$$

در اینجا $N(K, H)$ نقطه است که H دارای $N(K, H)$ نقطه است
 و $N(K, H)$ نقطه است که H دارای $N(K, H)$ نقطه است

$$N(K, H)$$

$$\frac{1}{n} \log \left(\frac{1}{\varepsilon} \right)$$

$$\frac{1}{n} \log \left(\frac{1}{\varepsilon} \right)$$

در اینجا $N(K, H)$ نقطه است که H دارای $N(K, H)$ نقطه است
 و $N(K, H)$ نقطه است که H دارای $N(K, H)$ نقطه است

$$\varepsilon(h) \leq \left(\min_{h \in H} \varepsilon(h) \right) + \sqrt{\frac{1}{n} \log \left(\frac{1}{\varepsilon} \right)}$$

در اینجا $N(K, H)$ نقطه است که H دارای $N(K, H)$ نقطه است
 و $N(K, H)$ نقطه است که H دارای $N(K, H)$ نقطه است

$$N(K, H)$$

مقدار $\frac{1}{N} \sum_{i=1}^N \log \frac{1}{p(x_i)}$ را محاسبه کنید. (مقدار این عبارت را در مورد داده های زیر محاسبه کنید)

$$N=11$$

داده های زیر را در نظر بگیرید:

$$x = \left(\frac{3}{11}, \frac{6}{11}, \frac{1}{11}, \frac{3}{11}, \frac{6}{11}, \frac{1}{11}, \frac{3}{11}, \frac{6}{11}, \frac{1}{11}, \frac{3}{11}, \frac{6}{11} \right)$$

$$\left[\frac{3 \times 2}{1 - (1+1)N} + \frac{8}{1} \log \frac{2}{1} \right] \times m \times m$$

و همچنین مقدار $\frac{1}{N} \sum_{i=1}^N \log \frac{1}{p(x_i)}$ را محاسبه کنید. (مقدار این عبارت را در مورد داده های زیر محاسبه کنید)

$$N=11$$

$$m = \frac{1}{N} \sum_{i=1}^N \log \frac{1}{p(x_i)}$$

مقدار این عبارت را محاسبه کنید.

موضوع: سیم (مطالعه مورد)

موضوع: سیم (مطالعه مورد)

در صورتی که ...

← هندسای تابع هزینه →

- فرض است θ پارامتر مجهول و λ که هزینه هر خط است \min شود (موضوع: λ از چه چیزها)
- ① آمارهای مربوط به داده ها
 - ② آمارهای مربوط به
 - ③ ستر درایه های هزینه
 - ④ هزینه های مربوط به λ و λ را در این مورد است
 - ⑤ محدودیت های λ می
 - ⑥ محدودیت های λ می

شرط KKT (کاربرد: به عنوان λ کوبر)

\min - max دوگان

دوگان λ را می توان

به دست آورد λ را می توان

عبارت λ را می توان

طوبیہ کے لئے ہر قسم کی
معاذی اللہ عنہم (وہ لوگ جن کے لئے اللہ سے
معاذ ہے) کے لئے ہر قسم کی

$$(\text{MDO} = 0) \left| \frac{\partial \mathcal{L}}{\partial \psi} \right|_{\psi = \psi_0} = 0$$

$$\theta_{\text{max}} = \theta_c - \pi / \theta_c (1 + \theta_c^2)^{-1}$$

[illegible][illegible]

$$\Delta p(t) = \frac{p(t) - p(t-1)}{p(t)} \quad \left| \quad \frac{p(t)}{p(t)} \right| \quad \frac{p(t)}{p(t)} = 1$$

در بیان کلی، θ اولیه $\theta = 0$ است.

$$\Delta \theta = -\frac{\partial S(\theta)}{\partial \theta}$$

$$(\Delta \theta = 0) \Rightarrow \frac{\partial S(\theta)}{\partial \theta} = 0$$

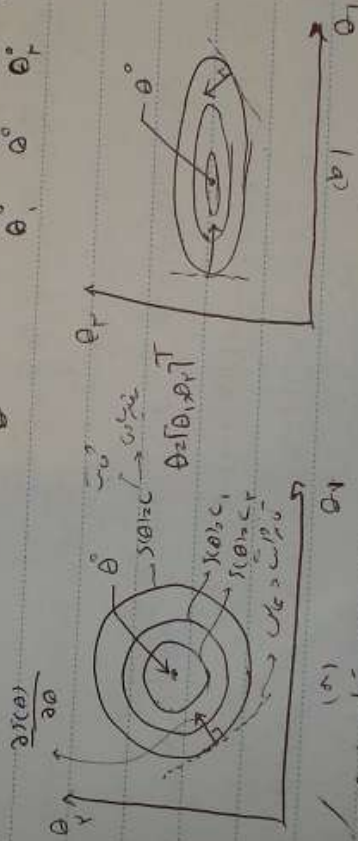

در اینجا باید دید که θ در هر دو حالت $\theta = 0$ و $\theta = \pi$ چه تفاوتی دارد.

معمولاً $\theta = 0$ را می‌گیریم.

در اینجا $\theta = 0$ را می‌گیریم.

در اینجا $\theta = 0$ را می‌گیریم.

در اینجا $\theta = 0$ را می‌گیریم. θ در اینجا $\theta = 0$ را می‌گیریم.



در اینجا $\theta = 0$ را می‌گیریم. θ در اینجا $\theta = 0$ را می‌گیریم.

در اینجا $\theta = 0$ را می‌گیریم.

در اینجا $\theta = 0$ را می‌گیریم.

Subject:

$J(\theta) = \frac{1}{2} \sum_{i=1}^n (y_i - \hat{y}_i)^2$ در اینجا y_i داده ها و \hat{y}_i پیش بینی ها هستند
 $\frac{\partial J(\theta)}{\partial \theta} = - \sum_{i=1}^n (y_i - \hat{y}_i) X_i$ اینجا X_i بردار ویژگی است
 $\frac{\partial J(\theta)}{\partial \theta} = 0 \Rightarrow \sum_{i=1}^n (y_i - \hat{y}_i) X_i = 0$ این معادله را برای یافتن θ حل می کنند

این معادله را می توان به صورت ماتریسی نوشت:

$$X^T (y - \hat{y}) = 0$$
که در آن X ماتریس ویژگی ها، y بردار مقادیر هدف و \hat{y} بردار پیش بینی ها است.

این معادله را می توان به صورت زیر نیز نوشت:

$$X^T X \theta = X^T y$$
این معادله را می توان به روش گسسته حل کرد.

اگر $X^T X$ معکوس پذیر باشد، می توانیم θ را به صورت زیر پیدا کنیم:

$$\theta = (X^T X)^{-1} X^T y$$

این فرمول را می توان به صورت زیر نیز نوشت:

$$\theta = (X^T X + \lambda I)^{-1} X^T y$$
این فرمول برای جلوگیری از مشکل معکوس پذیری استفاده می شود.

در اینجا λ پارامتر تنظیم می باشد که می تواند به صورت زیر انتخاب شود:

$$\lambda = \frac{1}{\text{trace}(X^T X)}$$

این فرمول را می توان به صورت زیر نیز نوشت:

$$\theta = (X^T X + \lambda I)^{-1} X^T y$$

این فرمول را می توان به صورت زیر نیز نوشت:

$$\theta = (X^T X + \lambda I)^{-1} X^T y$$

$$\hat{\sigma}(t) = \sigma(\hat{\sigma}(t))$$

$$\hat{\sigma}(t) = (L - \mu) \hat{\sigma}(t-1)$$

$$\hat{\sigma}(t) = \hat{\sigma}(t-1) + \hat{\sigma}(t-1)$$

در اینجا می بینیم که $\hat{\sigma}(t)$ به $\hat{\sigma}(t-1)$ وابسته است.

$$\hat{\sigma}(t) = \hat{\sigma}(t-1) + \hat{\sigma}(t-1)$$

$$\hat{\sigma}(t) = \hat{\sigma}(t-1) + \hat{\sigma}(t-1)$$

$$\hat{\sigma}(t) = \hat{\sigma}(t-1) + \hat{\sigma}(t-1)$$

$$\hat{\sigma}(t) = \hat{\sigma}(t-1) + \hat{\sigma}(t-1)$$

سپس می توانیم بنویسیم که $\hat{\sigma}(t)$ به $\hat{\sigma}(t-1)$ وابسته است.

توجه داشته باشید که $\hat{\sigma}(t)$ به $\hat{\sigma}(t-1)$ وابسته است.

در اینجا می بینیم که $\hat{\sigma}(t)$ به $\hat{\sigma}(t-1)$ وابسته است.

در اینجا می بینیم که $\hat{\sigma}(t)$ به $\hat{\sigma}(t-1)$ وابسته است.

در اینجا می بینیم که $\hat{\sigma}(t)$ به $\hat{\sigma}(t-1)$ وابسته است.

$$\hat{\sigma}(t) = \hat{\sigma}(t-1) + \hat{\sigma}(t-1)$$

در اینجا می بینیم که $\hat{\sigma}(t)$ به $\hat{\sigma}(t-1)$ وابسته است.

$$\hat{\sigma}(t) = \hat{\sigma}(t-1) + \hat{\sigma}(t-1)$$

$$\hat{\sigma}(t) = \hat{\sigma}(t-1) + \hat{\sigma}(t-1)$$

در اینجا می بینیم که $\hat{\sigma}(t)$ به $\hat{\sigma}(t-1)$ وابسته است.

Date: / /

Subject:

Unit 2: Discrete-time signals

Continuous-time signals
Discrete-time signals

minimize S(0)

base $AD = b$

max $AD = b$


Discrete-time signals

hence A has full row rank

who are fine?

→ Regularity assumption

درستی یا نادرستی را مشخص کنید:
 ① در یک سیستم، بارها می‌توانند به هم وابسته باشند.



درستی یا نادرستی را مشخص کنید:

